



Engenharia de Produto de Inteligência Artificial

Canvas do modelo, ciclo de vida, requisitos próprios de inteligência artificial, validação, operação e monitoramento.

Produto	Crosscheck BR — checagem cruzada de fatos em larga escala
Documento	O que é próprio de um produto de inteligência artificial: o canvas do modelo, o ciclo de vida, os requisitos RNF06 a RNF09, a validação, a operação e o monitoramento
Data deste documento	30 de setembro de 2026
Equipe	Thiago Correia Gonzaga, Gabriella Oliveira de Souza Dias, Maria Eduarda Denis Duarte Marques, Guilherme Silva Dutra, Eliane Orlandin do Carmo, Daltro Oliveira Vinuto

Um produto de inteligência artificial difere de um software tradicional em quatro pontos: depende de dados que mudam, tem comportamento probabilístico, precisa de operação contínua e só funciona como sistema integrado. Este documento registra como o Crosscheck BR trata cada um deles.

Como este documento se liga ao de requisitos. Cada dado fica em um único lugar. Os números do modelo e dos dados, os indicadores, as regras de negócio e as pendências estão na Engenharia de Requisitos; aqui eles são citados pelo identificador (RF, RNF, RN, HU, IND, P) ou por link, sem repetição. Onde o texto diz **proposta**, o valor precisa ser validado pela equipe.

1. Machine Learning Canvas

O canvas resume, em uma página, como o modelo gera valor: da coleta de dados ao uso da predição. A coluna “Detalhes” aponta para onde cada bloco é desenvolvido.

A predição é um indício, não uma decisão. Desde o pull request nº 4, o modelo não entra na avaliação: a propensão vem só das checagens de agências e da postura das fontes, e a predição aparece na resposta como sinal de estilo, ao lado do nível (RN11).

Bloco	Resumo	Detalhes
Proposta de valor	Estimar a propensão de um texto ser desinformação e mostrar as evidências, para a pessoa decidir se compartilha. Para quem recebe notícias em aplicativos de mensagem, para estudantes e professores, para jornalistas e checadores	Requisitos, seção 1
Tarefa de aprendizado de máquina	Classificação binária de texto em português. Entrada: o texto da notícia. Saída: probabilidade calibrada de ser desinformação	Requisitos, seção 4.1
Decisões	A predição é exibida como sinal de estilo, com a ressalva de que não é veredito, e não altera a propensão (RN11). Não aprova, não bloqueia e não rotula nada automaticamente	Seção 3
Predições	A cada consulta, em tempo real, uma vez por texto. O modelo se abstém em textos curtos (RN04)	RNF06
Fontes de dados	Conjunto FakenewsBR, com rótulos em camadas; agências de checagem; portais de notícias; busca de notícias recentes	Requisitos, seção 4.4
Coleta de dados	O coletor percorre os portais do catálogo; os votos de avaliação registram o texto e a propensão informada. Os votos precisam de curadoria antes de virar rótulo	Requisitos, seção 4.4; pendências P05 e P08
Variáveis de entrada	O próprio texto; não há variáveis construídas à mão. Em estudo: ocultar nomes de pessoas e lugares no treino, para o modelo não decorar quem aparece em boatos. Tamanho do texto, grupo de origem e canal servem para medir vieses, não para treinar	RNF09

Bloco	Resumo	Detalhes
Construção do modelo	Ajuste das seis últimas camadas do BERTimbau, duas passagens pelos dados, com pesos por grupo de origem e calibração em conjunto separado. Um treino leva cerca de 7 horas sem placa de vídeo, ou de 30 a 55 minutos com uma, em caderno na nuvem. A frequência de retreino ainda não está definida	Seção 6; pendência P13
Avaliação antes da implantação	Métrica principal: acurácia no pior grupo de origem. Recortes obrigatórios por grupo, canal, tamanho do texto e variedade do português. O modelo precisa superar o de referência	Requisitos, seção 4.2
Avaliação em produção e monitoramento	Sistema completo medido em casos rotulados (<code>eval/</code>); registro de cada execução em <code>runs/</code> ; sinais de desvio	Requisitos, seção 4.3; seção 10

2. Ciclo de vida do produto

Fase	O que existe hoje	Onde está	Situação
Planejamento	Requisitos levantados em sessão de ideias da equipe; roteiro em quatro fases	Engenharia de Requisitos, <code>ROADMAP.md</code>	Atendido
Preparação de dados	Coleta em agências e portais, remoção de duplicados, rótulos em camadas, separação de treino e teste por agrupamento de textos semelhantes	Repositório FakenewsBR: <code>investigation/expansion/</code> , <code>models/v6/prepare_v6.py</code>	Atendido
Engenharia do modelo	Ajuste do BERTimbau com pesos por grupo de origem; 23 experimentos e 4 controles; revisão crítica do desenho experimental	FakenewsBR: <code>models/v6/train_bertimbau_v6.py</code> , <code>models/v6/autoresearch/</code>	Atendido
Avaliação do modelo	Métricas por grupo de origem, por canal e por tamanho de texto; comparação com o modelo de referência	FakenewsBR: <code>models/v6/compare/</code> , <code>scripts/analise_por_tamanho.py</code>	Atendido
Implantação	Pesos publicados como versão no repositório; o robô carrega o modelo por configuração	<code>factcheck_mvp/modelo_fake.py</code>	Parcial: manual (seção 9)

Fase	O que existe hoje	Onde está	Situação
Operação	Limites de custo e de requisições, limites de tempo por etapa, instância única do robô	<code>factcheck_mvp/config.py</code> , <code>factcheck_mvp/api.py</code>	Parcial: sem automação (P12)
Monitoramento e avaliação	Registro de cada execução (etapas, chamadas, fontes, decisão); reprodução determinística; avaliação com casos rotulados	<code>factcheck_mvp/telemetry.py</code> , <code>factcheck_mvp/replay.py</code> , <code>eval/</code>	Parcial: sem acompanhamento agregado (P07)

3. Decisões e jornadas

Os objetivos do produto e os indicadores que os medem estão em Requisitos, seções 1.2 e 1.4.

3.1 Decisões que o sistema apoia

O sistema **apoia** decisões; não automatiza nenhuma (RF12, RF14).

Decisão	Quem decide	O que o sistema entrega	Requisitos
Compartilhar ou não uma mensagem	A pessoa que recebeu	Propensão, fontes e três perguntas para conferir	RF12, RF13, RF14
Em que fonte confiar	A pessoa	Fontes lado a lado, com o selo de cada agência	RF06, RF07
Vale uma checagem aprofundada?	Jornalista ou checador	O que já foi checado e por quem	RF04
Um portal novo entra no catálogo?	Equipe do projeto	Proposta de inclusão para curadoria	RNF03, P05

3.2 Jornadas de uso

Jornada	Passos	Histórias
Mensagem recebida em aplicativo	A pessoa copia o texto, envia ao robô, acompanha o progresso, lê a resposta e, se quiser, avalia se ajudou	HU01, HU08, HU10, HU12, HU13

Jornada	Passos	Histórias
Consulta pela página na internet	A pessoa cola o texto no formulário e lê a mesma resposta do robô	HU14
Link de notícia	A pessoa envia o link; se o portal não é do catálogo, o robô pede o texto	HU02
Título ou boato curto	A pessoa envia uma frase; o modelo não opina (RN04); a busca e as checagens respondem	HU01, HU05, HU06
Imagem, vídeo ou áudio	A pessoa envia mídia; o robô explica que não analisa e orienta	HU03
Auditoria pela equipe	A equipe consulta o registro de etapas de uma resposta	HU11

4. Estratégia do produto mínimo viável

Um produto mínimo viável de inteligência artificial prova que o modelo resolve um problema real, antes do acabamento visual.

Elemento	Critério	Situação
Desempenho mínimo viável	O modelo supera o de referência no pior grupo, não só na média	Atendido: ver a comparação em Requisitos, seção 4.2
Calibração	A confiança exibida corresponde ao acerto real	Atendido: mesma seção
Estratégia de dados	Dados rotulados suficientes, sem vazamento entre treino e teste	Atendido: Requisitos, seção 4.4
Potencial de integração	O canal escolhido reduz o atrito de adoção	Atendido: RF01 e RF15
Valor sem o modelo	O produto continua útil se o modelo estiver fora	Atendido: RF04 a RF07 não dependem do modelo
Validação com pessoas reais	Pessoas do público-alvo usam e avaliam	Pendente: P11

O limite conhecido do produto mínimo viável é o desempenho do modelo em textos curtos (RN04; pendência P09).

5. Requisitos não funcionais próprios de inteligência artificial

Continuam a numeração dos RNF01 a RNF05, que estão em Requisitos, seção 3, e seguem o mesmo padrão de redação: verbo no infinitivo e objeto no título, e o atributo de qualidade logo abaixo.

RNF06 — Responder dentro dos limites de tempo e de custo

Atributo de qualidade: desempenho e escalabilidade.

Critério	Valor atual	Meta proposta	Situação
Latência do modelo próprio	37 milissegundos por texto, sem placa de vídeo (medido em um Apple M4)	Abaixo de 200 milissegundos	Atendido
Latência da resposta completa (IND11)	Medida pela avaliação: mediana de 39,9 segundos por caso na iteração 0, com modelo de linguagem local. Limites: 60 segundos no agente de busca, 180 na interface de programação, 240 por chamada ao modelo de linguagem e 600 no julgamento das fontes	Mediana abaixo de 30 segundos	Parcial: P07
Vazão	30 requisições por minuto por endereço de rede	A definir com o uso real	Parcial
Capacidade diária e controle de custo	100 buscas e 50 chamadas ao modelo de linguagem por dia. Uma consulta com julgamento das fontes faz várias chamadas, e a avaliação completa precisou de limites de 1.000	200 consultas por dia	Pendente
Picos de demanda	Sem fila. Buscas repetidas em até uma hora vêm de cache; o reaproveitamento da resposta inteira está só na branch de melhorias (P01)	Fila com limite de concorrência	Parcial

RNF07 — Proteger os dados e o sistema contra uso indevido

Atributo de qualidade: segurança e privacidade.

Critério	Como é tratado	Situação
Dados em trânsito	Conexões cifradas com o Telegram e com os serviços externos de busca e de modelo de linguagem. A interface de programação própria ainda não tem cifragem configurada	Parcial
Dados em repouso	Cada execução grava em <code>runs/</code> o texto da consulta, as chamadas ao modelo de linguagem e as fontes, sem identificar a pessoa. Não há prazo de retenção	Parcial: P15
Chaves de serviço	Lidas do ambiente, fora do controle de versão, sem valor padrão	Atendido
Acesso a endereços	Só portais do catálogo, com limite de tamanho e de tempo	Atendido
Injeção de instruções	Texto da pessoa e das páginas é tratado como dado. A delimitação explícita e o teste de blindagem estão só na branch de melhorias	Parcial: P01
Texto que imita jornal para enganar o modelo	O modelo reage ao formato: um boato escrito como reportagem recebe probabilidade baixa. Mitigação: o modelo não entra na avaliação (RN11)	Atendido no produto; pendente no modelo (P09)
Invenção pelo modelo de linguagem	O julgamento de cada fonte só vale com um trecho citado que exista na página (semelhança mínima de 0,9)	Atendido
Envenenamento dos dados de avaliação	Votos podem ser manipulados e exigem curadoria antes de entrar em treino	Pendente: P05
Envenenamento do catálogo	Portais novos não valem na consulta em que são descobertos, mas entram no catálogo sem aprovação	Parcial: P05
Lei Geral de Proteção de Dados	Aviso no início da conversa; orientação para não enviar dados pessoais	Parcial: falta a política de retenção (P15)

RNF08 — Manter a resposta disponível diante de falhas

Atributo de qualidade: confiabilidade e manutenção.

Critério	Como é tratado	Situação
Falha de uma etapa	A resposta continua e a falha vira limitação declarada (RF11)	Atendido

Critério	Como é tratado	Situação
Falha do modelo de linguagem	Regras fixas extraem as afirmações; sem julgamento das fontes, a resposta é "indeterminada" (RN12)	Atendido, com perda de qualidade (P02)
Falha da busca	O sistema usa só o índice de checagens, se ligado	Atendido
Falha do modelo próprio	A etapa é registrada como falha e a resposta segue sem o sinal de estilo	Atendido
Estabilidade da resposta (IND07)	O estilo saiu da avaliação e as faixas ficaram simétricas, o que remove a principal causa de propensões diferentes para a mesma notícia. Falta medir	Parcial: P04
Frequência de retreino	Não definida. Proposta: a cada três meses, ou quando um sinal da seção 10 passar do limite	Pendente: P13
Monitoramento de desvio	Ver seção 10	Parcial: P07
Retorno à versão anterior	O modelo é trocado por configuração. Hoje só há uma versão publicada; sem ela, o substituto identificado como provisório assume	Parcial

RNF09 — Medir e mitigar os vieses do modelo e dos dados

Atributo de qualidade: ética e justiça.

O conjunto de dados tem vieses conhecidos, medidos no conjunto de teste descrito em Requisitos, seção 4.2. Os valores que já estão naquela seção não são repetidos aqui.

Viés	Evidência	Mitigação	Situação
Origem do texto	Em 11 grupos de origem, todos os textos têm o mesmo rótulo. Um modelo pode aprender a origem em vez do conteúdo	Treino só nos grupos informativos, com pesos; a métrica principal é o pior grupo	Parcial: ver o pior grupo na seção 4.2 dos requisitos
Canal	Acerto de 0,97 em portais, 0,85 em alegações de agências, 0,67 em mensagens de aplicativo, 0,63 em alegações externas	Relato por canal em toda avaliação	Parcial

Viés	Evidência	Mitigação	Situação
Tamanho do texto	Acerto menor nas notícias verdadeiras curtas: ver a tabela por tamanho na seção 4.2 dos requisitos	O modelo não opina em textos curtos (RN04)	Atendido no robô; pendente no modelo (P09)
Classe	A maioria dos textos de treino é desinformação, e a precisão na classe verdadeira é menor: ver a seção 4.2 dos requisitos	Calibração feita em um conjunto separado do treino e do teste	Parcial
Variedade do português	Acerto de 0,71 em português de Portugal, contra 0,84 no do Brasil	Relato separado	Pendente
Tema e posição política	Não medido	Proposta: medir o acerto por tema e por espectro político das fontes	Pendente: P14

Salvaguardas do produto, independentes do modelo: a resposta nunca é binária (RF12); nenhum domínio é bloqueado por lista (RN06); termos partidários são proibidos no texto da resposta (RNF02); o modelo de linguagem não redige a conclusão (RN08); o modelo próprio não altera a propensão (RN11).

6. Reprodutibilidade

O que é versionado	Como	Situação
Código	Git, com uma mudança por registro e testes em cada uma	Atendido
Dados	Arquivos grandes publicados como versão do repositório. A assinatura de cada arquivo fica registrada em <code>prepare_stats.json</code>	Atendido
Separação de treino e teste	Arquivo próprio, com assinatura registrada e semente fixa (42)	Atendido
Modelo	Pesos publicados como versão <code>modelo-v6-R0</code> , com a calibração no mesmo pacote	Atendido
Experimentos	Cada execução grava <code>run_config.json</code> com as assinaturas do código, dos dados e da separação, e todos os parâmetros	Atendido

O que é versionado	Como	Situação
Ambiente	Lista de dependências; versões das bibliotecas registradas no relatório do treino	Parcial: P16
Avaliação do sistema	Casos rotulados em <code>eval/</code> (70 de desenvolvimento e um conjunto reservado); gravação das respostas externas para reprodução determinística (<code>factcheck_mvp/replay.py</code>)	Atendido

Assinaturas da execução R0: dados `596b0911...`, separação `6df3d748...`, código de treino `dfa29ba7...`. Com o mesmo código, os mesmos dados e a mesma semente, o treino é determinístico. Os requisitos sobre os dados estão em Requisitos, seção 4.4.

7. Validação

Um produto de inteligência artificial é validado de duas formas, e cada parte do sistema usa a que lhe cabe.

	Partes determinísticas	Partes probabilísticas
O que é	Regras, formatação, segurança, contratos de entrada e saída	Modelo próprio, modelo de linguagem, avaliação final
Como validar	Testes automatizados com resultado fixo	Desempenho estatístico em conjuntos de referência; <code>eval/run.py --gate</code> compara com a rodada anterior
Critério	Todos os testes passam	Indicadores acima das metas; nenhum grupo abaixo do mínimo
Onde está	Requisitos, seção 5.1: requisito, arquivo e teste	Modelo: seção 4.2. Sistema em uso: seção 4.3. Resultado e experiência: seção 1.4, IND04 a IND13
Situação	Atendido: 319 testes passando	Parcial: o modelo está medido; o sistema completo tem uma medição reconstruída em 70 casos, e falta uma rodada completa (P04)

8. Experiência de uso para sistemas probabilísticos

Prática	Requisito que a garante	Situação
Comunicar capacidades e limitações	RF01 (mensagem inicial), RF11 (limitações em cada resposta)	Atendido
Explicar como a decisão foi tomada	RNF01, RF11, RF13	Atendido
Indicar o nível de confiança	RF09	Atendido
Projetar para falhas	RNF08; estado "indeterminada" (RF13)	Atendido
Manter a pessoa no controle	RF12, RF14	Atendido
Linguagem acessível	RNF04	Parcial: P11

9. Operação e implantação

Prática	Situação atual	Proposta
Integração contínua	Os testes e a comparação da avaliação (<code>eval/run.py --gate</code>) são executados à mão	Executar os testes a cada envio ao repositório (P12)
Treinamento contínuo	O treino é manual, em computador local ou em caderno na nuvem	Retreino periódico, com o mesmo conjunto de teste (P13)
Entrega contínua	O robô é iniciado por um roteiro local	Implantação automatizada depois dos testes
Modo sombra	Não existe	O modelo novo recebe as consultas reais sem influenciar a resposta, e os resultados são comparados (P13)
Liberação gradual	Não existe	Liberar o modelo novo para uma parte das consultas antes de todas
Dois ambientes	Não existe	Manter a versão anterior pronta para retorno imediato

Prática	Situação atual	Proposta
Troca do modelo	Por configuração, sem alterar código (RNF05)	Manter

Situação geral: **Pendente**. O produto está em fase de validação, e a automação está prevista na fase 3 do `ROADMAP.md`.

10. Monitoramento contínuo

Um produto de inteligência artificial nunca está concluído: o desempenho cai quando o mundo muda. Notícias mudam de tema todos os dias, e as formas de desinformação também.

Fenômeno	O que é	Sinal proposto	Situação
Desvio dos dados	As consultas ficam diferentes dos textos de treino	Proporção de consultas curtas demais para o modelo; distribuição do tamanho dos textos	Pendente: P07
Desvio de conceito	O que caracteriza desinformação muda	Acerto no conjunto de alegações checadas, refeito todo mês com checagens novas (IND04, IND05)	Pendente: P07
Deterioração de desempenho	Os indicadores caem	Proporção de respostas "indeterminada" (IND03); avaliações negativas (IND09); distribuição da probabilidade do modelo	Pendente: P07
Falhas de serviço	Busca ou modelo de linguagem fora	Proporção de etapas com falha	Gravado por execução; sem agregação

Cada execução já grava seus sinais em `runs/` (`docs/TELEMETRIA.md`). Falta agregá-los e acompanhá-los ao longo do tempo (P07).

As pendências citadas neste documento (P01 a P16) estão reunidas, com impacto e esforço, em Requisitos, seção 5.5.